



INSTITUTO POLITÉCNICO NACIONAL
UNIDAD PROFESIONAL INTERDISCIPLINARIA EN INGENIERIA
Y TECNOLOGÍAS AVANZADAS



UNIDAD DE APRENDIZAJE

Multimedia

ALUMNO

Cerecedo Gallegos Jesus

Boleta

2021640171

PROFESOR

Noé Sierra Romero

TEMA

Speech To Text

Grupo: 3TM2

Practica 6



El reconocimiento automático del habla (*Automatic Speech Recognition*, ASR), comúnmente denominado *Speech-to-Text* (STT), es la subdisciplina de la inteligencia artificial, el procesamiento del lenguaje natural (NLP) y el procesamiento digital de señales (DSP) que convierte señales acústicas de voz humana en representaciones textuales estructuradas.

Su objetivo principal es mapear una secuencia continua de ondas sonoras variantes en el tiempo a una secuencia discreta de palabras o tokens lingüísticos.

Formulación Matemática Fundamental

Tradicionalmente, el problema del reconocimiento de voz se formula bajo el paradigma probabilístico Bayesiano. Dada una secuencia de observaciones acústicas extraídas del audio $X = (x_1, x_2, \dots, x_T)$, el sistema busca determinar la secuencia de palabras $W^* = (w_1, w_2, \dots, w_N)$ que maximice la probabilidad a posteriori $P(W|X)$:


$$W^* = \arg \max_W P(W|X) = \arg \max_W \frac{P(X|W)P(W)}{P(X)} = \arg \max_W P(X|W) P(W)$$

En este marco de trabajo clásico, la búsqueda se divide en dos componentes estadísticos independientes:

1. **Modelo Acústico $P(X|W)$:** Evalúa la probabilidad de que la secuencia de características acústicas X haya sido generada por la pronunciación de las palabras W .
2. **Modelo de Lenguaje $P(W)$:** Mide la probabilidad a priori de que la secuencia de palabras W sea gramatical y semánticamente válida dentro del idioma objetivo.

Evolución de las Arquitecturas de STT

La arquitectura interna de los sistemas STT ha experimentado una transición paradigmática desde los modelos híbridos basados en cadenas de Markov hasta las redes neuronales profundas de extremo a extremo (*End-to-End*, E2E).



1. Sistemas Híbridos Clásicos (HMM-GMM / HMM-DNN)



Durante décadas, el estándar industrial se basó en Modelos Ocultos de Markov (HMM) combinados con Modelos de Mezclas Gaussianas (GMM) o Redaciones Neuronales Profundas (DNN):

- **Extracción de características:** La señal de audio continua se digitaliza (habitualmente a 16 kHz) y se divide en ventanas superpuestas (de 20 a 25 ms). De cada ventana se extraen coeficientes espectrales como los *Mel-Frequency Cepstral Coefficients* (MFCC) o bancos de filtros de Mel (*log-mel filterbanks*).
- **Modelado fonético:** Un lexicón o diccionario de pronunciación traduce las palabras a fonemas. Los HMM gestionan la variabilidad temporal y la duración de las emisiones de dichos fonemas.

2. Arquitecturas de Extremo a Extremo (*End-to-End*)

Los sistemas modernos reemplazan los componentes independientes (modelo acústico, lexicón y modelo de lenguaje) por una única red neuronal unificada optimizada de forma conjunta.

- **Connectionist Temporal Classification (CTC):** Permite entrenar redes recurrentes (RNN) o convolucionales directamente sobre pares de audio y texto sin requerir una alineación temporal previa a nivel de marco. Introduce un token nulo (*blank*) para gestionar transiciones y repeticiones.
- **RNN-Transducer (RNN-T):** Diseñado para aplicaciones de transmisión en tiempo real (*streaming*), procesa la entrada acústica a medida que llega con una latencia mínima, separando la red de predicción de la red acústica.
- **Modelos Encoder-Decoder basados en Transformers:** Arquitecturas globales (como Whisper o Conformer) convierten la señal de espectrograma Mel mediante un codificador convolucional/Transformer y generan tokens de texto autoregresivamente mediante atención cruzada (*cross-attention*). Estos modelos destacan por su robustez ante acentos y ruido de fondo al ser entrenados con decenas de miles de horas de audio supervisado de forma masiva.

Desafíos Técnicos Principales

A pesar de los avances impulsados por el aprendizaje profundo, la precisión del reconociendo automático del habla se ve afectada por factores físicos, lingüísticos y computacionales:

- **Variaciones en la señal de entrada:** El fenómeno de desacoplamiento acústico provocado por la reverberación del entorno, la respuesta en frecuencia de diferentes micrófonos y la relación señal-ruido (SNR) degradan el rendimiento de los modelos.



- **Variabilidad inter e intrapersonal:** Factores como la tasa de habla, la edad, el sexo, la entonación, las disfluencias (pausas, muletillas) y las variaciones dialectales o acentos no nativos introducen dispersión en las representaciones latentes.
- **Ambigüedad fonética y palabras homófonas:** Múltiples palabras o secuencias poseen una pronunciación idéntica pero significados e ortografías completamente distintas según el contexto.
- **Compromiso entre latencia y precisión:** En aplicaciones interactivas en tiempo real, el sistema debe decodificar la señal con retardos inferiores a 200 ms, restringiendo el uso de modelos masivos con atención global bidireccional que requieren ver todo el contexto del audio antes de emitir un resultado.

Aplicaciones Prácticas

La tecnología STT constituye la capa primaria de ingesta de datos en múltiples dominios de ingeniería y software:

- **Interfaces de voz e interacción persona-computadora:** Servir como front-end acústico para asistentes virtuales y agentes de voz en entornos embebidos y móviles.
- **Transcripción médica y legal:** Digitalización automatizada de dictados clínicos e interrogatorios, integrada con vocabulario técnico mediante ajuste fino (*fine-tuning*) de los modelos de lenguaje subyacentes.
- **Subtitulado automático y traducción simultánea:** Generación de subtítulos alineados temporalmente en transmisiones en vivo y pipelines de traducción voz a voz (*Speech-to-Speech Translation*).
- **Análisis de telefonía y Call Centers:** Procesamiento de audio en la nube para análisis de sentimientos, minería de datos en registros de atención al cliente e indexación semántica de archivos sonoros.



INSTITUTO POLITÉCNICO NACIONAL
UNIDAD PROFESIONAL INTERDISCIPLINARIA EN INGENIERIA
Y TECNOLOGIAS AVANZADAS



 **Texto a Voz**

Hola que haces

Idioma / Voz:
Microsoft Jorge Online (Natur

Velocidad: 1

Tono: 1

▶ Reproducir

⏸ Pausar

■ Detener

☒ Lectura completada.