



INSTITUTO POLITÉCNICO NACIONAL
UNIDAD PROFESIONAL INTERDISCIPLINARIA EN INGENIERIA
Y TECNOLOGIAS AVANZADAS



UNIDAD DE APRENDIZAJE

Multimedia

ALUMNO

Cerecedo Gallegos Jesus

Boleta

2021640171

PROFESOR

Noé Sierra Romero

TEMA

Text To Speech

Grupo: 3TM2


Practica 7



Text-to-Speech (TTS), o síntesis de voz a partir de texto, es el proceso computacional de conversión de texto escrito en una señal de audio hablada inteligible y de aspecto natural. Conecta el procesamiento del lenguaje natural (NLP) con el procesamiento digital de señales (DSP) y el aprendizaje profundo generativo para mapear una secuencia discreta de caracteres o fonemas en una forma de onda acústica continua en el dominio del tiempo $x[n]$.

Arquitectura de la Pipeline Modular

Los sistemas TTS neuronales modernos transforman el texto en audio mediante una canalización de múltiples etapas o un modelo unificado de extremo a extremo (*end-to-end*):



1. Front-end Textual (Procesamiento y Fonematización)

El *front-end* textual transforma el texto plano en una secuencia estandarizada de tokens lingüísticos aptos para el modelado acústico:

- **Normalización de Texto:** Convierte tokens no estándar —como números, fechas, divisas, abreviaturas y símbolos— en su forma canónica textual completa (ej. "\$15" → "quince dólares").
- **Conversión Grafema a Fonema (G2P):** Traduce el texto normalizado a secuencias fonémicas mediante diccionarios de pronunciación o redes neuronales G2P para resolver palabras homógrafas según el contexto sintáctico (ej. "canto" como sustantivo o verbo).
- **Análisis Prosódico y Lingüístico:** Identifica límites de oraciones, árboles sintácticos y puntuación para inferir el acento, los contornos de tono (*pitch*) y la ubicación de las pausas.

2. Modelo Acústico (Generación de Espectrogramas)

El modelo acústico mapea la secuencia de fonemas o *embeddings* de caracteres en una representación intermedia tiempo-frecuencia, comúnmente un **espectrograma de Mel** $M \in \mathbb{R}^{F \times T}$, donde F denota el número de bandas de frecuencia Mel y T los marcos temporales.

- **Modelos Autorregresivos (ej. Tacotron 2):** Predicen los marcos del espectrograma de Mel secuencialmente marco por marco mediante mecanismos de atención.



Aunque son altamente expresivos, sufren de alta latencia en la inferencia y posibles fallos de alineación (omisión o repetición de palabras).

- **Modelos No Autorregresivos (ej. FastSpeech 2, Conformer TTS):** Predicen todos los marcos del espectrograma en paralelo utilizando predictores explícitos de duración, módulos de alineación y adaptadores de varianza (tono, energía). Esto elimina el sesgo de exposición, acelera la velocidad de inferencia y garantiza un control robusto de la duración.

3. Vocoder Neuronal (Síntesis de Forma de Onda)

Dado que los espectrogramas de Mel omiten la información de fase y comprimen la resolución frecuencial, se requiere un *vocoder* neuronal para sintetizar la señal de audio continua en el dominio del tiempo $x[n]$ a partir del espectrograma.

- **Vocoders Generativos (ej. HiFi-GAN, WaveNet, BigVGAN):** Emplean Redes Generativas Antagónicas (GANs), procesos de difusión o flujos normalizadores para sintetizar audio continuo a tasas de muestreo objetivo (ej. 22.05 kHz, 24 kHz o 48 kHz).
- **Reconstrucción de Fase:** Los *vocoders* modernos basados en GAN utilizan discriminadores multiescala y multiperiodo para predecir la dinámica de fase de alta frecuencia y las señales transitorias, eliminando artefactos de fase metálicos.

Modelos de Lenguaje de Audio y Extremo a Extremo (*End-to-End*)

Los desarrollos recientes en TTS abandonan las canalizaciones desacopladas en favor de paradigmas generativos unificados:

- **Inferencia Variacional y Flujos Normalizadores (ej. VITS):** Integra el codificador de texto, el predictor de duración, los flujos normalizadores y el decodificador GAN en una sola red entrenada de extremo a extremo con límites inferiores variacionales y pérdidas antagónicas, eliminando la necesidad de generar un espectrograma intermedio explícito.
- **Modelos de Lenguaje de Audio (ej. VALL-E, Bark):** Tratan el TTS como una tarea de modelado de lenguaje sobre códecs de audio neuronales. Las señales de audio se discretizan en representaciones multicódigo mediante códecs neuronales (como EnCodec o DAC), y arquitecturas Transformer predicen estos tokens acústicos de forma autorregresiva condicionados a *prompts* de texto y hablante.

Métricas de Rendimiento y Desafíos Técnicos

La calidad operativa y la viabilidad de despliegue de las arquitecturas TTS se evalúan mediante métricas clave de ingeniería:



- **Factor de Tiempo Real (RTF - *Real-Time Factor*):** Mide la eficiencia de inferencia como la relación entre el tiempo de procesamiento para generar el audio T_{proc} y la duración total del audio sintetizado T_{audio} :

$$\text{RTF} = \frac{T_{\text{proc}}}{T_{\text{audio}}}$$

Un $\text{RTF} < 1.0$ es indispensable para aplicaciones interactivas de transmisión en tiempo real (*streaming*).

- **MOS y WER:** Se evalúa de manera subjetiva mediante la Puntuación Media de Opinión (*Mean Opinion Score*, MOS) para la naturalidad, u objetivamente mediante la Tasa de Error de Palabras (*Word Error Rate*, WER) procesando el audio generado a través de un sistema de Reconocimiento Automático del Habla (ASR).
- **Control de Prosodia y Expresividad:** Modelado de la entonación natural, inflexiones emocionales y disfluencias sin causar inestabilidad vocal ni degradación acústica.
- **Clonación de Voz *Zero-Shot*:** Extracción del timbre, acento y acústica del entorno a partir de una breve muestra de audio (≤ 3 segundos) para condicionar la generación de voz de hablantes no vistos previamente mediante *embeddings* de hablante.